

Exercice 1 On veut étudier la liaison entre les caractères : "être fumeur" (plus de 20 cigarettes par jour, pendant 10 ans) et "avoir un cancer de la gorge", sur une population de 1000 personnes, dont 500 sont atteintes d'un cancer de la gorge. Voici les résultats observés:

Observé	cancer	non cancer	marge
fumeur	342	258	600
non fumeur	158	242	400
marge	500	500	1000

Faire un test d'indépendance pour établir la liaison entre ces caractères.

Exercice 2 Nous allons analyser les données de ventes de deux produits dans plusieurs magasins. Le tableau ci-dessous présente les chiffres de ventes des produits A et B.

Magasin	Ventes Produit A	Ventes Produit B
1	2	2
2	6	2
3	6	4
4	10	4

Table 1: Ventes des Produits A et B par Magasin

1. Définir la matrice des données X .
2. Calculer la moyenne et l'écart-type de chaque variable.
3. Déterminer la matrice centrée et réduite X_{cr} .
4. Déterminer la matrice des corrélations entre les variables U .
5. Déterminer le polynôme caractéristique de la matrice de corrélation $P(\lambda)$.
6. Calculer les valeurs propres.
7. Déterminer les axes principaux et le pourcentage d'information expliqué par chaque axe.
8. Déterminer les composantes principales.
9. Déterminer la contribution de chaque individu à l'explication du phénomène, ainsi que celle des variables dans l'analyse.
10. Calculer la contribution de chaque individu à la construction des axes principaux.

Correction des exercices de Révision.

Exercice 1:

- Pour tester si les deux variables qualitatives sont indépendantes, on utilise le test chi-2 (χ^2).
- Pour cela, on formule deux hypothèses H_0 et H_1 :
 H_0 : Les deux variables sont indépendantes.
 H_1 : Les deux variables sont dépendantes.
- Puisque $\alpha = P(\text{Rejeter } H_0 / H_0 \text{ est vraie})$ n'est pas fixé dans l'énoncé, on prend $\alpha = 5\%$.
- Pour l'échantillon, sa taille est $n = 1000$.
- L'étape suivante consiste à calculer les fréquences sous l'hypothèse H_0 . Pour le faire, on transforme le tableau des effectifs observés par les fréquences observées et finalement calculer les fréquences sous H_0 on détaille ces étapes ci-dessous.

Déjà les données sont: ~~Données~~

1)

O_i	C	non-C	
F	342	258	600
non-F	158	242	400
	500	500	1000

c'est le tableau des effectifs observés

2)

	C	non-C	
F	0,342	0,258	0,6
non-F	0,158	0,242	0,4
	0,5	0,5	1

c'est le tableau des fréquences observées
calculées par $f_{ij} = \frac{n_{ij}}{n} = \frac{n_{ij}}{1000}$

3) sous H_0 :

	C	non-C	
F	0,3	0,3	0,6
non-F	0,2	0,2	0,4
	0,5	0,5	1

c'est le tableau des fréquences attendues (si H_0 est vraie.)
 $f_{ij} = f_{i.} \cdot f_{.j}$

et donc les effectifs attendus et le tableau des fréquences attendues multiplié par l'effectif total 1000

E_i	C	non-C	
F	300	300	600
non-F	200	200	400
	500	500	1000

→ Tableau des effectifs attendus

• Par la suite, on calcule le test χ^2_0 .

$$\chi^2_0 = \sum_{i=1}^4 \frac{(\theta_i - E_i)^2}{E_i} = \frac{(342 - 300)^2}{300} + \frac{(258 - 300)^2}{300} + \frac{(158 - 200)^2}{200} + \frac{(242 - 200)^2}{200}$$

$$\boxed{\chi^2_0 = 29,4}$$

L'étape suivante consiste à chercher $\chi^2_{\alpha; \nu}$ dans le tableau de la loi chi-2 avec α déjà fixé à 5% et ν le degré de liberté calculé par:

$$\nu = (n-1)(m-1) \text{ avec}$$

• n : le nbre des modalités de la première variable.

• m : " " " " " deuxième " "

ici, on a $n=m=2$ donc $\nu=1$.

Par tableau de la loi chi-2, on trouve $\chi^2_{0,05;1} = 3,841$

Décision: Puisque $\chi^2_0 > \chi^2_{0,05;1}$, on rejette H_0 c-à-d les deux variables sont dépendantes

Exercice 2

1) La matrice de données est : $X = \begin{pmatrix} 2 & 2 \\ 6 & 2 \\ 6 & 4 \\ 10 & 4 \end{pmatrix}$

on note dans la suite X_1 : la première colonne et par X_2 la deuxième colonne.

2) La moyenne de X_1 : $\bar{X}_1 = \frac{1}{4} \sum_{i=1}^4 x_1^i$ avec x_1^i est la i -ème modalité de la variable X_1 et $\bar{X}_2 = \frac{1}{4} \sum_{i=1}^4 x_2^i$

donc $\bar{X}_1 = \frac{2+6+6+10}{4} = 6$

$$\bar{X}_2 = \frac{2+2+4+4}{4} = 3$$

l'écart-type : noté $\sigma(X_1)$ et $\sigma(X_2)$

$$\sigma(X_1) = \sqrt{\frac{1}{4} \sum_{i=1}^4 (x_1^i - \bar{X}_1)^2}$$

$$= \sqrt{\frac{1}{4} [(2-6)^2 + (6-6)^2 + (6-6)^2 + (10-6)^2]}$$

$$\boxed{\sigma(X_1) = \sqrt{8} = 2\sqrt{2}}$$

$$\sigma(X_2) = \sqrt{\frac{1}{4} \sum_{i=1}^4 (x_2^i - \bar{X}_2)^2}$$

$$= \sqrt{\frac{1}{4} [(2-3)^2 + (2-3)^2 + (4-3)^2 + (4-3)^2]}$$

$$\boxed{\sigma(X_2) = 1}$$

page 4 3/ La matrice centrée réduite:

X_{cr} est calculée en soustrayant la moyenne de chaque valeur de la variable X_1 ou X_2 et en divisant par l'écart type.
par exemple pour la 1^{ère} variable: $\frac{x_1^i - \bar{x}_1}{\sigma(x_1)}$, de même pour la 2^{ème} variable, donc:

$$X_{cr} = \begin{pmatrix} \frac{2-6}{2\sqrt{2}} & \frac{2-3}{1} \\ \frac{6-6}{2\sqrt{2}} & \frac{2-3}{1} \\ \frac{6-6}{2\sqrt{2}} & \frac{4-3}{1} \\ \frac{10-6}{2\sqrt{2}} & \frac{4-3}{1} \end{pmatrix} = \begin{pmatrix} -\sqrt{2} & -1 \\ 0 & -1 \\ 0 & 1 \\ \sqrt{2} & 1 \end{pmatrix}$$

$$4/ U = \frac{1}{n} X_{cr}^T X_{cr} = \frac{1}{4} \begin{pmatrix} -\sqrt{2} & 0 & 0 & \sqrt{2} \\ -1 & -1 & 1 & 1 \end{pmatrix} \begin{pmatrix} -\sqrt{2} & -1 \\ 0 & -1 \\ 0 & 1 \\ \sqrt{2} & 1 \end{pmatrix} \\ = \begin{pmatrix} 1 & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & 1 \end{pmatrix}$$

$$5) P(\lambda) = \det(U - \lambda I_2) = \begin{vmatrix} 1-\lambda & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & 1-\lambda \end{vmatrix} = (1-\lambda)^2 - \left(\frac{\sqrt{2}}{2}\right)^2 \\ = \left(1-\lambda - \frac{\sqrt{2}}{2}\right) \left(1-\lambda + \frac{\sqrt{2}}{2}\right) = \left(\frac{2-\sqrt{2}}{2} - \lambda\right) \left(\frac{2+\sqrt{2}}{2} - \lambda\right)$$

6) Les valeurs propres sont les racines de $P(\lambda)$.

$$P(\lambda) = 0 \Leftrightarrow \lambda_1 = \frac{2+\sqrt{2}}{2}; \lambda_2 = \frac{2-\sqrt{2}}{2} \text{ (Dans l'ordre décroissant)}$$

7/ Les axes principaux:

- le 1^{er} axe principal noté v_1 :

on cherche U_1 tq $(U - \lambda_1 I_2) U_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ puis on normalise U_1 pour obtenir v_1 . c-à-d:

on note $U_1 = \begin{pmatrix} x \\ y \end{pmatrix}$

$$\begin{pmatrix} -\sqrt{2}/2 & \sqrt{2}/2 \\ \sqrt{2}/2 & -\sqrt{2}/2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Leftrightarrow \begin{pmatrix} -\frac{\sqrt{2}}{2}x + \frac{\sqrt{2}}{2}y \\ \frac{\sqrt{2}}{2}x - \frac{\sqrt{2}}{2}y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\Leftrightarrow \begin{cases} -\frac{\sqrt{2}}{2}x + \frac{\sqrt{2}}{2}y = 0 \\ \frac{\sqrt{2}}{2}x - \frac{\sqrt{2}}{2}y = 0 \end{cases} \Leftrightarrow x = y$$

donc U_1 devient: $U_1 = \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x \\ x \end{pmatrix} = x \begin{pmatrix} 1 \\ 1 \end{pmatrix}$

on prend $x = 1$ donc $U_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ et $\|U_1\| = \sqrt{(1)^2 + (1)^2} = \sqrt{2}$

$v_1 = \frac{1}{\|U_1\|} U_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ est le 1^{er} axe principal.

- le 2^{ème} axe principal noté v_2 , on suit les m^êmes étapes et les m^êmes notations, on a:

$$(U - \lambda_2 I_2) U_2 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Leftrightarrow \begin{pmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\Leftrightarrow x = -y \quad \text{donc} \quad U_2 = \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x \\ -x \end{pmatrix} = x \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

pour $y = 1$; $U_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$; $\|U_2\| = \sqrt{(-1)^2 + 1^2} = \sqrt{2}$

$v_2 = \frac{1}{\|U_2\|} U_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}$ est le 2^{ème} axe principal

le pourcentage d'information expliqué par :

i) le premier axe principal qu'on note I_1

$$I_1 = \frac{\lambda_1}{\sum_{i=1}^2 \lambda_i} = \frac{2 + \sqrt{2}}{2} \approx 85\%$$

ii) le 2^{ème} axe principal qu'on note I_2 ,

$$I_2 = \frac{\lambda_2}{\sum_{i=1}^2 \lambda_i} = \frac{2 - \sqrt{2}}{2} \approx 15\%$$

8/ les composantes principales :

i) La 1^{ère} composante principale c^1 , $c^1 = X_{cr} v_1^c$

$$C^1 = \frac{1}{\sqrt{2}} \begin{pmatrix} -\sqrt{2} & -1 \\ 0 & -1 \\ 0 & 1 \\ \sqrt{2} & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{-\sqrt{2}-1}{\sqrt{2}} \\ -1/\sqrt{2} \\ 1/\sqrt{2} \\ \frac{\sqrt{2}+1}{\sqrt{2}} \end{pmatrix}$$

ii) La 2^{ème} composante principale c^2 ,

$$C^2 = X_{cr} v_2^c = \frac{1}{\sqrt{2}} \begin{pmatrix} -\sqrt{2} & -1 \\ 0 & -1 \\ 0 & 1 \\ \sqrt{2} & 1 \end{pmatrix} \begin{pmatrix} -1 \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{\sqrt{2}-1}{\sqrt{2}} \\ -1/\sqrt{2} \\ 1/\sqrt{2} \\ \frac{-\sqrt{2}+1}{\sqrt{2}} \end{pmatrix}$$

9 et 10 : Voir le cours, les slides 29-33