

Formules LaTeX - Référence Rapide

Analyse de Données et Statistiques

AmineGR03

31 janvier 2026

Table des matières

Chapitre 3 : Corrélation et Régression

Coefficient de corrélation de Pearson

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (1)$$

Régression linéaire simple

Modèle

$$Y = \beta_0 + \beta_1 X + \varepsilon \quad (2)$$

Estimateurs

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (3)$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad (4)$$

Résidus

$$e_i = y_i - \hat{y}_i \quad (5)$$

Coefficient de détermination R^2

$$R^2 = \frac{SS_{\text{exp}}}{SS_{\text{tot}}} = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} \quad (6)$$

où :

- $SS_{\text{tot}} = \sum_{i=1}^n (y_i - \bar{y})^2$: variabilité totale
- $SS_{\text{res}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$: variabilité non expliquée (résiduelle)
- $SS_{\text{exp}} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$: variabilité expliquée

Régression linéaire multiple

Modèle matriciel

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (7)$$

où :

- $\mathbf{Y}$: vecteur des observations ($n \times 1$)
- $\mathbf{X}$: matrice des données ($n \times (p+1)$), première colonne = 1 pour l'intercept
- $\boldsymbol{\beta}$: vecteur des coefficients de régression ($(p+1) \times 1$)
- $\boldsymbol{\varepsilon}$: vecteur des erreurs aléatoires ($n \times 1$)

Estimateur MCO (Moindres Carrés Ordinaires)

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \quad (8)$$

R² ajusté

$$R^2_{\text{ajusté}} = 1 - (n - 1) \frac{1 - R^2}{n - p - 1} \quad (9)$$

où :

- n : nombre d'observations
- p : nombre de variables explicatives

Chapitre 5 : Loïs de Probabilité

Variables aléatoires discrètes

Espérance

$$E(X) = \sum_x x \cdot p(x) \quad (10)$$

Variance

$$\text{Var}(X) = E[(X - E(X))^2] = E(X^2) - [E(X)]^2 \quad (11)$$

où :

$$E(X^2) = \sum_x x^2 \cdot p(x) \quad (12)$$

Écart-type

$$\sigma(X) = \sqrt{\text{Var}(X)} \quad (13)$$

Variables aléatoires continues

Probabilité sur un intervalle

$$P(a \leq X \leq b) = \int_a^b f(x) dx \quad (14)$$

Espérance

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f(x) dx \quad (15)$$

Variance

$$\text{Var}(X) = \int_{-\infty}^{+\infty} (x - E(X))^2 f(x) dx = E(X^2) - [E(X)]^2 \quad (16)$$

où :

$$E(X^2) = \int_{-\infty}^{+\infty} x^2 \cdot f(x) dx \quad (17)$$

Écart-type

$$\sigma(X) = \sqrt{\text{Var}(X)} \quad (18)$$

Loi de Bernoulli**Fonction de masse de probabilité**

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\} \quad (19)$$

ou de manière équivalente :

- $P(X = 1) = p$
- $P(X = 0) = 1 - p$

Espérance et variance

$$E(X) = p, \quad \text{Var}(X) = p(1 - p) \quad (20)$$

Notation

$$X \sim \text{Ber}(p)$$

Loi Binomiale**Fonction de masse de probabilité**

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n \quad (21)$$

où le coefficient binomial est :

$$\binom{n}{k} = \frac{n!}{k!(n - k)!} \quad (22)$$

Espérance et variance

$$E(X) = np, \quad \text{Var}(X) = np(1 - p) \quad (23)$$

Notation

$$X \sim B(n, p)$$

Loi Exponentielle**Fonction de densité de probabilité**

$$f_X(x) = \lambda e^{-\lambda x}, \quad x \geq 0 \quad (24)$$

Fonction de répartition

$$F_X(x) = 1 - e^{-\lambda x}, \quad x \geq 0 \quad (25)$$

Espérance et variance

$$E(X) = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2} \quad (26)$$

Propriété importante : Absence de mémoire

$$P(X > s + t | X > s) = P(X > t) \quad (27)$$

Notation

$$X \sim \text{Exp}(\lambda)$$

Loi Normale (Gaussienne)**Fonction de densité de probabilité**

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R} \quad (28)$$

Propriétés

- **Symétrie** : La courbe est symétrique par rapport à la moyenne μ
- **Espérance et variance** :

$$E(X) = \mu, \quad \text{Var}(X) = \sigma^2 \quad (29)$$

Fonction de répartition

$$F_X(x) = P(X \leq x) = \frac{1}{2} \left[1 + \text{erf}\left(\frac{x-\mu}{\sigma\sqrt{2}}\right) \right] \quad (30)$$

où la fonction d'erreur est :

$$\text{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt \quad (31)$$

Notation

$$X \sim N(\mu, \sigma^2)$$

Loi Normale Centrée Réduite**Définition**

Si $X \sim N(\mu, \sigma^2)$, alors la variable centrée réduite :

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1) \quad (32)$$

Fonction de densité

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}, \quad z \in \mathbb{R} \quad (33)$$

Fonction de répartition

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^z \phi(t) dt \quad (34)$$

Propriétés importantes

- $\Phi(-z) = 1 - \Phi(z)$
- $P(a \leq Z \leq b) = \Phi(b) - \Phi(a)$
- Pour $X \sim N(\mu, \sigma^2)$: $P(a \leq X \leq b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$

Règle des 3 sigmas

Pour $X \sim N(\mu, \sigma^2)$:

- $P(\mu - \sigma \leq X \leq \mu + \sigma) \approx 0.68$ (68%)
- $P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 0.95$ (95%)
- $P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 0.997$ (99.7%)

Chapitre 5 (Suite) : Tests d'Hypothèses

Test sur la moyenne (variance connue)

Statistique de test

$$Z_0 = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1) \quad (35)$$

Si H_0 est vraie, alors $Z_0 \sim N(0, 1)$ (pour n grand ou si $X \sim N(\mu, \sigma^2)$).

Règle de décision bilatérale

- **Rejeter** H_0 si $|Z_0| > z_{\alpha/2}$
 - **Accepter** H_0 si $|Z_0| \leq z_{\alpha/2}$
- où $z_{\alpha/2}$ est le quantile d'ordre $1 - \alpha/2$ de la loi normale standard.
- Valeurs critiques usuelles :**
- $\alpha = 0.05 : z_{0.025} = 1.96$
 - $\alpha = 0.01 : z_{0.005} = 2.576$

Test sur la moyenne (variance inconnue)

Statistique de test

$$T_0 = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1} \quad (36)$$

où S est l'écart-type empirique :

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (37)$$

Si H_0 est vraie et $X \sim N(\mu, \sigma^2)$, alors $T_0 \sim t_{n-1}$ (loi de Student à $n - 1$ degrés de liberté).

Règle de décision bilatérale

- **Rejeter** H_0 si $|T_0| > t_{\alpha/2; n-1}$
 - **Accepter** H_0 si $|T_0| \leq t_{\alpha/2; n-1}$
- où $t_{\alpha/2; n-1}$ est le quantile d'ordre $1 - \alpha/2$ de la loi de Student à $n - 1$ degrés de liberté.

Tests unilatéraux

Test unilatéral à gauche

Hypothèses :

$$H_0 : \mu = \mu_0 \text{ (ou } \mu \geq \mu_0), \quad H_1 : \mu < \mu_0$$

Règle de rejet :

- Si σ connu : rejeter H_0 si $Z_0 < -z_\alpha$
- Si σ inconnu : rejeter H_0 si $T_0 < -t_{\alpha; n-1}$

Test unilatéral à droite**Hypothèses :**

$$H_0 : \mu = \mu_0 \text{ (ou } \mu \leq \mu_0), \quad H_1 : \mu > \mu_0$$

Règle de rejet :

- Si σ connu : rejeter H_0 si $Z_0 > z_\alpha$
- Si σ inconnu : rejeter H_0 si $T_0 > t_{\alpha;n-1}$

Niveau critique observé (P-value)**Définition**

Le **niveau critique observé** (ou **P-value**, notée PV) est la valeur minimale de α telle que H_0 est toujours rejetée.

Calcul de la P-value**Variance connue (bilatéral) :**

$$PV = 2(1 - \Phi(|z_0|)) \quad (38)$$

Variance inconnue (bilatéral) :

$$PV = 2P(T > |t_0|) \quad \text{avec } T \sim t_{n-1} \quad (39)$$

Interprétation

- Si $PV < \alpha$: rejeter H_0
- Si $PV \geq \alpha$: ne pas rejeter H_0

Test d'ajustement du khi-deux (χ^2)**Statistique de test**

$$\chi_0^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \sim \chi_{k-p-1}^2 \quad (40)$$

où :

- k : nombre de classes
- p : nombre de paramètres estimés
- O_i : effectifs observés
- E_i : effectifs attendus

Effectifs attendus

$$E_i = n \times p_i^{(0)} \quad (41)$$

où :

$$p_i^{(0)} = P(X \in V_i | H_0 \text{ est vraie}) \quad (42)$$

Règle de décision

Pour un niveau critique α donné :

— **Rejeter** H_0 si $\chi_0^2 > \chi_{\alpha;\nu}^2$

— **Accepter** H_0 si $\chi_0^2 \leq \chi_{\alpha;\nu}^2$

où $\chi_{\alpha;\nu}^2$ est le quantile d'ordre $1 - \alpha$ de la loi χ_ν^2 avec $\nu = k - p - 1$.

Chapitre 6 : Analyse en Composantes Principales (ACP)

Matrices

Matrice centrée

$$a_{ij} = x_{ij} - \bar{x}_j \quad (43)$$

Matrice centrée réduite

$$m_{ij} = \frac{x_{ij} - \bar{x}_j}{\sigma_j} \quad (44)$$

$$\sigma_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2} \quad (45)$$

où :

- $\bar{x}_j$: moyenne de la variable X_j
- σ_j : écart-type de la variable X_j

Matrice des variances-covariances

$$\mathbf{V} = \frac{1}{n} \mathbf{M}_c^T \mathbf{M}_c \quad (46)$$

où $\mathbf{M}_c^T$ est la transposée de la matrice centrée.

Matrice des corrélations

$$\mathbf{U} = \frac{1}{n} \mathbf{M}_{cr}^T \mathbf{M}_{cr} \quad (47)$$

où $\mathbf{M}_{cr}^T$ est la transposée de la matrice centrée réduite.

Inertie

Calcul

$$I_g = \frac{1}{n} \sum_{i=1}^n \sum_{k=1}^p (x_{ik} - \bar{x}_k)^2 = \sum_{k=1}^p \sigma_k^2 \quad (48)$$

Cas des données centrées-réduites

Si les données sont centrées et réduites :

- $I_g = p$
- $\mathbf{g}^\top = (0, 0, \dots, 0)$

Valeurs propres et vecteurs propres

Équation caractéristique

Pour chaque valeur propre λ_k , on trouve le vecteur propre associé $\mathbf{u}_k$ tel que :

$$\mathbf{U}\mathbf{u}_k = \lambda_k \mathbf{u}_k \quad (49)$$

Polynôme caractéristique

$$P(\lambda) = \det(\mathbf{U} - \lambda \mathbf{I}_p) = 0 \quad (50)$$

Ordre des valeurs propres

Les valeurs propres $\lambda_1, \lambda_2, \dots, \lambda_p$ sont ordonnées par ordre décroissant :

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0 \quad (51)$$

Composantes principales

Calcul

$$\mathbf{C}_1 = \mathbf{M}_{cr} \mathbf{u}_1 \quad (52)$$

$$\mathbf{C}_2 = \mathbf{M}_{cr} \mathbf{u}_2 \quad (53)$$

$$\vdots \quad (54)$$

$$\mathbf{C}_k = \mathbf{M}_{cr} \mathbf{u}_k \quad (55)$$

Propriétés

- **Centrées** : la moyenne de chaque composante est nulle
- **Variance** : la variance de la composante C_k est égale à la valeur propre λ_k
- **Non corrélées** : les composantes principales sont deux à deux non corrélées

Inertie expliquée

Inertie d'un axe

$$\text{Inertie axe } k = \frac{\lambda_k}{\sum_{i=1}^p \lambda_i} = \frac{\lambda_k}{I_g} \quad (56)$$

Pour des données centrées-réduites ($I_g = p$) :

$$\text{Inertie axe } k = \frac{\lambda_k}{p} \quad (57)$$

Inertie cumulée

L'inertie cumulée des k premiers axes est :

$$\text{Inertie cumulée} = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^p \lambda_i} \quad (58)$$

Contributions

Contribution d'un individu à l'inertie totale

$$\text{CONTR}(i) = \frac{1}{n} \sum_{j=1}^p \frac{m_{ij}^2}{I_g} \quad (59)$$

Pour des données centrées-réduites ($I_g = p$) :

$$\text{CONTR}(i) = \frac{1}{np} \sum_{j=1}^p m_{ij}^2 \quad (60)$$

Contribution d'une variable

$$\text{CONTR}(X_j) = \frac{1}{p} \sum_{i=1}^n \frac{m_{ij}^2}{I_g} \quad (61)$$

Contribution d'un individu à la construction d'un axe

$$\text{CONTR}(i, \text{axe } k) = \frac{1}{n} \frac{C_{ik}^2}{\lambda_k} \quad (62)$$

où C_{ik} est la coordonnée de l'individu i sur la composante principale C_k .

Opérations sur matrices

Multiplication matricielle

Pour $\mathbf{A}$ ($m \times n$) et $\mathbf{B}$ ($n \times p$) :

$$(\mathbf{AB})_{ij} = \sum_{k=1}^n a_{ik}b_{kj} \quad (63)$$

Transposée

$$(\mathbf{A}^T)_{ij} = a_{ji} \quad (64)$$

Propriétés importantes

- $(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T$
- $(\mathbf{A}^T)^T = \mathbf{A}$
- $(\mathbf{A}^{-1})^T = (\mathbf{A}^T)^{-1}$
- $(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1}$ (si les inverses existent)
- Si $\mathbf{A}$ est symétrique : $\mathbf{A}^T = \mathbf{A}$

Déterminant

Matrice 2×2

$$\det(\mathbf{A}) = \begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc \quad (65)$$

Matrice 3×3

$$\det(\mathbf{A}) = a(ei - fh) - b(di - fg) + c(dh - eg) \quad (66)$$

où $\mathbf{A} = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix}$.

Notes d'utilisation

- Utilisez `\begin{align}...\end{align}` pour les équations multi-lignes
- Utilisez `\text{}` pour le texte dans les formules mathématiques
- Utilisez `\,` pour un espacement fin dans les intégrales
- Les indices utilisent `_` et les exposants `^`
- Les vecteurs en gras utilisent `\mathbf{}` ou `\boldsymbol{}`
- Les matrices utilisent `\mathbf{}` ou `\boldsymbol{}`
- Les ensembles de nombres utilisent `\mathbb{}` (ex : $\mathbb{R}$, $\mathbb{N}$)