

Résumé Complet - Chapitre 3

Corrélation et Régression

AmineGR03

31 janvier 2026

Table des matières

Corrélation et Coefficient de Corrélation de Pearson

Définitions

Relation entre deux variables : Lien ou dépendance entre deux variables quantitatives.

Types de relations :

- Relation linéaire (droite)
- Relation non linéaire (courbe, parabole)
- Absence de relation (données dispersées)

Corrélation : Mesure statistique qui exprime la force et la direction de la relation entre deux variables quantitatives.

Important : Corrélation $\neq$ Causalité!

Types de corrélation

- **Positive** : Les deux variables augmentent ensemble
- **Négative** : Une variable augmente, l'autre diminue
- **Nulle** : Absence de relation linéaire

Coefficient de corrélation de Pearson

Formule principale

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (1)$$

où :

- x_i, y_i : valeurs observées
- $\bar{x}, \bar{y}$: moyennes des variables X et Y
- n : nombre d'observations

Propriétés

- $-1 \leq r \leq 1$
- $r = 1$: corrélation positive parfaite
- $r = -1$: corrélation négative parfaite
- $r = 0$: absence de corrélation linéaire

Interprétation de r

Valeur de $ r $	Interprétation
$0.9 \leq r \leq 1$	Très forte corrélation
$0.7 \leq r < 0.9$	Forte corrélation
$0.5 \leq r < 0.7$	Corrélation modérée
$0.3 \leq r < 0.5$	Faible corrélation
$0 \leq r < 0.3$	Très faible ou aucune corrélation

Précautions

- Corrélation $\neq$ causalité
- Présence de valeurs extrêmes (outliers) $\rightarrow$ influence sur r
- Relation non linéaire non détectée par Pearson
- Toujours visualiser les données

Autres coefficients de corrélation

- **Spearman** : pour données ordinales ou non linéaires
- **Kendall** : pour petites séries ordinales
- **Pearson** : uniquement pour relation linéaire et données quantitatives

Régression Linéaire Simple

Définition

Régression linéaire simple : Méthode statistique permettant de modéliser la relation entre une variable expliquée (réponse) Y et une variable explicative (prédicteur) X via une relation linéaire.

Modèle mathématique

$$Y = \beta_0 + \beta_1 X + \varepsilon \quad (2)$$

où :

- β_0 : ordonnée à l'origine (intercept)
- β_1 : coefficient directeur (pente)
- ε : erreur aléatoire

Hypothèses du modèle

1. Relation linéaire entre X et Y
2. Espérance nulle des erreurs : $E[\varepsilon] = 0$
3. Variance constante des erreurs : homoscedasticité
4. Indépendance des erreurs
5. Normalité des erreurs (optionnelle pour estimation, nécessaire pour les tests)

Estimation des paramètres par moindres carrés

Objectif

Minimiser la somme des carrés des erreurs :

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \quad (3)$$

Solutions (estimateurs)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (4)$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad (5)$$

Équation estimée

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X \quad (6)$$

Coefficient de détermination R^2

Définition

$$R^2 = \frac{SS_{\text{exp}}}{SS_{\text{tot}}} = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} \quad (7)$$

où :

- $SS_{\text{tot}} = \sum_{i=1}^n (y_i - \bar{y})^2$: variabilité totale
- $SS_{\text{res}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$: variabilité non expliquée (résiduelle)
- $SS_{\text{exp}} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$: variabilité expliquée

Interprétation de R^2

R^2	Interprétation
1	Le modèle explique parfaitement les données
0	Le modèle n'explique aucune variance
$0 < R^2 < 1$	Le modèle explique partiellement la variance

Plus R^2 est proche de 1, plus le modèle est performant.

Résidus

Définition

Un résidu est la différence entre la valeur observée et la valeur prédite :

$$e_i = y_i - \hat{y}_i \quad (8)$$

Rôle des résidus

- Évaluer la qualité de l'ajustement
- Identifier les valeurs aberrantes
- Vérifier les hypothèses (linéarité, homoscedasticité, indépendance, normalité)

Régression Linéaire Multiple

Définition

Régression linéaire multiple : Modélisation d'une variable réponse Y en fonction de plusieurs variables explicatives $X_1, X_2, \dots, X_p$.

Modèle mathématique

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_p X_{ip} + \varepsilon_i \quad (9)$$

Notation matricielle

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (10)$$

où :

- $\mathbf{Y}$: vecteur des observations ($n \times 1$)
- $\mathbf{X}$: matrice des données ($n \times (p+1)$), première colonne = 1 pour l'intercept
- $\boldsymbol{\beta}$: vecteur des coefficients de régression ($(p+1) \times 1$)
- $\boldsymbol{\varepsilon}$: vecteur des erreurs aléatoires ($n \times 1$)

Hypothèses du modèle

1. **Linéarité** : relation linéaire entre chaque X_j et Y
2. **Espérance nulle** : $E[\varepsilon_i] = 0$
3. **Homoscédasticité** : $\text{Var}(\varepsilon_i) = \sigma^2$ (constante)
4. **Indépendance** : les erreurs sont indépendantes
5. **Normalité** : $\varepsilon_i \sim N(0, \sigma^2)$ (pour les tests)

Estimation par moindres carrés ordinaires (MCO)

Objectif

Minimiser : $\min_{\boldsymbol{\beta}} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2$

Solution

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \quad (11)$$

Condition : $(\mathbf{X}^T \mathbf{X})$ doit être inversible (pas de colinéarité parfaite).

Interprétation des coefficients

- $\hat{\beta}_j$: variation moyenne de Y lorsque X_j augmente d'une unité, toutes les autres variables étant maintenues constantes
- $\hat{\beta}_0$: valeur prédite de Y lorsque toutes les variables explicatives valent 0 (intercept)

Qualité de l'ajustement

R² (coefficient de détermination)

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} \quad (12)$$

R² ajusté

$$R^2_{\text{ajusté}} = 1 - (n - 1) \frac{1 - R^2}{n - p - 1} \quad (13)$$

où :

- n : nombre d'observations
- p : nombre de variables explicatives

Remarque : $R^2_{\text{ajusté}} \leq R^2$

Le R^2 ajusté pénalise l'ajout de variables non pertinentes.

Opérations sur Matrices (Rappels)

Multiplication matricielle

Pour $\mathbf{A}$ ($m \times n$) et $\mathbf{B}$ ($n \times p$) :

$$(\mathbf{AB})_{ij} = \sum_{k=1}^n a_{ik}b_{kj} \quad (14)$$

Transposée

$$(\mathbf{A}^T)_{ij} = a_{ji} \quad (15)$$

Inverse

$$\mathbf{A}^{-1}\mathbf{A} = \mathbf{AA}^{-1} = \mathbf{I} \quad (16)$$

où $\mathbf{I}$ est la matrice identité.

Propriétés importantes

- $(\mathbf{AB})^T = \mathbf{B}^T\mathbf{A}^T$
- $(\mathbf{A}^T)^T = \mathbf{A}$
- $(\mathbf{A}^{-1})^T = (\mathbf{A}^T)^{-1}$
- $(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$ (si les inverses existent)

Exercice d'Application

Énoncé

Un chercheur étudie la relation entre le nombre d'heures d'étude par semaine (X) et la note obtenue à un examen (Y sur 20). Les données suivantes ont été collectées :

Étudiant	Heures d'étude (X)	Note (Y)
1	5	10
2	8	12
3	10	15
4	12	16
5	15	18
6	18	19
7	20	20

Questions :

1. Calculer le coefficient de corrélation de Pearson entre X et Y . Interpréter le résultat.
2. Estimer les paramètres β_0 et β_1 du modèle de régression linéaire simple $Y = \beta_0 + \beta_1 X + \varepsilon$.
3. Calculer le coefficient de détermination R^2 et interpréter.
4. Prédire la note d'un étudiant qui étudie 14 heures par semaine.
5. Calculer les résidus pour chaque observation et vérifier s'il y a des valeurs aberrantes.

Solution guidée

1. Calcul du coefficient de corrélation

Étape 1 : Calculer les moyennes

$$\bar{x} = \frac{5+8+10+12+15+18+20}{7} = 12.57$$

$$\bar{y} = \frac{10+12+15+16+18+19+20}{7} = 15.71$$

Étape 2 : Calculer les écarts et produits croisés

i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
1	-7.57	-5.71	43.20	57.30	32.60
2	-4.57	-3.71	16.96	20.90	13.76
3	-2.57	-0.71	1.82	6.60	0.50
4	-0.57	0.29	-0.17	0.33	0.08
5	2.43	2.29	5.56	5.90	5.24
6	5.43	3.29	17.87	29.48	10.82
7	7.43	4.29	31.87	55.20	18.40
Total			117.11	175.71	81.40

Étape 3 : Calculer r

$$r = \frac{117.11}{\sqrt{175.71 \times 81.40}} = \frac{117.11}{119.58} = 0.979 \quad (17)$$

Interprétation : $r = 0.979$ indique une **très forte corrélation positive** entre le nombre d'heures d'étude et la note obtenue.

2. Estimation des paramètres

$$\hat{\beta}_1 = \frac{117.11}{175.71} = 0.666 \quad (18)$$

$$\hat{\beta}_0 = 15.71 - 0.666 \times 12.57 = 7.34 \quad (19)$$

Équation estimée : $\hat{Y} = 7.34 + 0.666X$

3. Calcul de R^2

Étape 1 : Calculer les valeurs prédites $\hat{y}_i$

i	x_i	y_i	$\hat{y}_i = 7.34 + 0.666x_i$	$(y_i - \bar{y})^2$	$(\hat{y}_i - \bar{y})^2$	$(y_i - \hat{y}_i)^2$
1	5	10	10.67	32.60	25.40	0.45
2	8	12	12.67	13.76	9.24	0.45
3	10	15	14.00	0.50	2.92	1.00
4	12	16	15.33	0.08	0.14	0.45
5	15	18	17.33	5.24	2.63	0.45
6	18	19	19.33	10.82	13.11	0.11
7	20	20	20.66	18.40	24.50	0.44
Total				81.40	76.98	3.35

Étape 2 : Calculer R^2

$$R^2 = \frac{76.98}{81.40} = 0.946 \quad (20)$$

Interprétation : Le modèle explique **94.6%** de la variance des notes. C'est un excellent ajustement.

4. Prédiction

Pour $X = 14$ heures :

$$\hat{Y} = 7.34 + 0.666 \times 14 = 16.66 \quad (21)$$

Prédiction : Un étudiant qui étudie 14 heures par semaine devrait obtenir environ **16.66/20**.

5. Résidus

Tous les résidus sont petits (inférieurs à 1 en valeur absolue), donc **pas de valeurs aberrantes** détectées.

i	y_i	$\hat{y}_i$	$e_i = y_i - \hat{y}_i$
1	10	10.67	-0.67
2	12	12.67	-0.67
3	15	14.00	1.00
4	16	15.33	0.67
5	18	17.33	0.67
6	19	19.33	-0.33
7	20	20.66	-0.66

Résumé des Formules Clés

Corrélation

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \quad (22)$$

Régression simple

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \quad (23)$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad (24)$$

Régression multiple (matricielle)

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \quad (25)$$

R^2

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} \quad (26)$$

Résidus

$$e_i = y_i - \hat{y}_i \quad (27)$$