

Chap3

Relation entre les variables : Corrélation et Coefficient de Corrélation de Pearson

Pr. A. Fadil

EMSI RABAT

30 octobre 2025

Objectifs du cours

- Comprendre la notion de relation entre deux variables.
- Identifier les types de relations (linéaire, non linéaire).
- Définir et interpréter la corrélation.
- Calculer et interpréter le coefficient de corrélation de Pearson.
- Connaître les limites et les précautions.

Relation entre deux variables

- Relation = lien ou dépendance entre deux variables.
- Exemples :
 - ▶ nombre des heures de préparation et la note.
 - ▶ Température et consommation d'électricité.
- Importance :
 - ▶ Prévoir, comprendre ou modéliser un phénomène.

Types de relations

- Relation linéaire (droite).
- Relation non linéaire (courbe, parabole).
- Absence de relation (données dispersées).

Qu'est-ce que la corrélation ?

- Mesure statistique qui exprime la force et la direction de la relation entre deux variables quantitatives.
- Corrélation \neq causalité !
- Se lit souvent sur un **nuage de points** (scatter plot).

Types de corrélation

- Positive : les deux variables augmentent ensemble.
- Négative : une variable augmente, l'autre diminue.
- Nulle : absence de relation linéaire.

Coefficient de corrélation de Pearson

Définition

$$r = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2}}$$

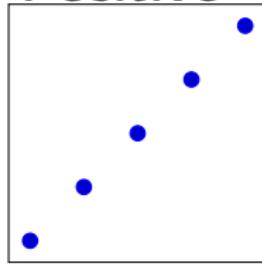
- $-1 \leq r \leq 1$.
- $r = 1$: corrélation positive parfaite.
- $r = -1$: corrélation négative parfaite.
- $r = 0$: absence de corrélation linéaire.

Interprétation de r

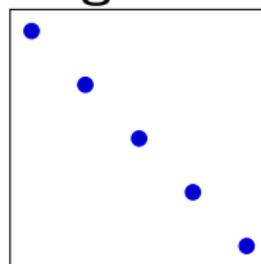
- $0.9 \leq |r| \leq 1$: très forte corrélation.
- $0.7 \leq |r| < 0.9$: forte corrélation.
- $0.5 \leq |r| < 0.7$: corrélation modérée.
- $0.3 \leq |r| < 0.5$: faible corrélation.
- $0 \leq |r| < 0.3$: très faible ou aucune corrélation.

Illustration graphique

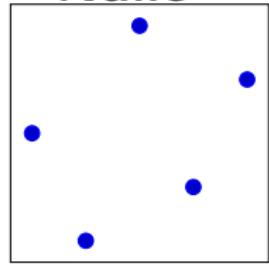
Positive



Négative



Nulle



Exemple simple

Un enseignant souhaite étudier s'il existe un lien entre le *temps de révision* et la *note obtenue à un test*. Il interroge 5 étudiants et note, pour chacun, le nombre d'heures passées à réviser la veille du test ainsi que la note obtenue sur 10.

i	X_i (heures)	Y_i (note)
1	1	2
2	2	4
3	3	5
4	4	4
5	5	5

- Moyennes : $\bar{x} = 3$, $\bar{y} = 4$
- Numérateur : $\sum(x_i - \bar{x})(y_i - \bar{y}) = (1 - 3)(2 - 4) + \dots + (5 - 3)(5 - 4) = 6$
- Dénominateur :
$$\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2} = \sqrt{10 \times 6} = 7.75$$
- $r = 6/7.75 \approx 0.77 \rightarrow$ forte corrélation positive.

Précautions

- Corrélation \neq causalité.
- Présence de valeurs extrêmes (*outliers*) \rightarrow influence r .
- Relation non linéaire non détectée par Pearson.
- Toujours visualiser les données.

Remarque

Le coefficient de Pearson ne s'applique qu'aux relations linéaires entre variables quantitatives.

- Spearman : données ordinaires ou non linéaires.
- Kendall : petites séries ordinaires.
- Pearson : uniquement pour relation linéaire et données quantitatives.

Exercice d'application

Données :

i	Taille (cm)	Poids (kg)
1	150	50
2	160	55
3	170	65
4	180	70
5	190	80

Questions :

- Calculer les moyennes \bar{x} et \bar{y} .
- Calculer le coefficient r .
- Interpréter le résultat.
- Vérifier à l'aide d'un nuage de points.

Exercice d'application

Données :

i	Taille (cm)	Poids (kg)
1	150	50
2	160	55
3	170	65
4	180	70
5	190	80

Questions :

- Calculer les moyennes \bar{x} et \bar{y} .
- Calculer le coefficient r .
- Interpréter le résultat.
- Vérifier à l'aide d'un nuage de points.

Correction de l'exercice

1. Moyennes :

$$\bar{x} = \frac{150 + 160 + 170 + 180 + 190}{5} = 170$$

$$\bar{y} = \frac{50 + 55 + 65 + 70 + 80}{5} = 64$$

Correction de l'exercice

2. Calcul des écarts et produits croisés :

i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
1	-20	-14	280	400	196
2	-10	-9	90	100	81
3	0	1	0	0	1
4	10	6	60	100	36
5	20	16	320	400	256

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = 280 + 90 + 0 + 60 + 320 = 750$$

$$\sum (x_i - \bar{x})^2 = 400 + 100 + 0 + 100 + 400 = 1000$$

$$\sum (y_i - \bar{y})^2 = 196 + 81 + 1 + 36 + 256 = 570$$

Correction de l'exercice

3. Calcul du coefficient r :

$$r = \frac{750}{\sqrt{1000 \times 570}} = \frac{750}{\sqrt{570000}} = \frac{750}{755} \approx 0.993$$

4. Interprétation :

- $r \approx 0.99$: très forte corrélation positive entre la taille et le poids.
- En pratique, à mesure que la taille augmente, le poids augmente presque proportionnellement.

Correction de l'exercice

3. Calcul du coefficient r :

$$r = \frac{750}{\sqrt{1000 \times 570}} = \frac{750}{\sqrt{570000}} = \frac{750}{755} \approx 0.993$$

4. Interprétation :

- $r \approx 0.99$: très forte corrélation positive entre la taille et le poids.
- En pratique, à mesure que la taille augmente, le poids augmente presque proportionnellement.

Résumé

- Corrélation : relation entre deux variables.
- Pearson : mesure linéaire, sensible aux outliers.
- Toujours visualiser les données.
- Corrélation \neq causalité.

Questions / Discussion

- Avez-vous rencontré des variables corrélées dans votre domaine ?
- Pourquoi est-il dangereux de confondre corrélation et causalité ?

Régression Linéaire Simple

Pr. A. Fadil

EMSI RABAT

30 octobre 2025

Objectifs du cours

- Comprendre le concept de régression linéaire simple
- Maîtriser l'estimation des paramètres par les moindres carrés
- Évaluer la qualité de l'ajustement
- Appliquer le modèle à des exemples réels

Définition

Régression linéaire simple : une méthode statistique permettant de modéliser la relation entre une variable expliquée ou réponse Y et une variable explicative ou prédicteur X via une relation linéaire :

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

où :

- β_0 est l'ordonnée à l'origine (intercept)
- β_1 est le coefficient directeur (pente)
- ε est une erreur aléatoire

Hypothèses du modèle

- ① Relation linéaire entre X et Y
- ② Les erreurs ε ont une espérance nulle : $\mathbb{E}[\varepsilon] = 0$
- ③ Variance constante des erreurs : homoscédasticité
- ④ Indépendance des erreurs
- ⑤ Normalité des erreurs (optionnelle pour estimation, nécessaire pour les tests)

Estimation des paramètres

Méthode des moindres carrés : minimiser la somme des carrés des erreurs :

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Solutions :

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Coefficient de détermination R^2

Définition :

$$R^2 = \frac{SS_{\text{exp}}}{SS_{\text{tot}}} = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

- $SS_{\text{tot}} = \sum(y_i - \bar{y})^2$: variabilité totale
- $SS_{\text{res}} = \sum(y_i - \hat{y}_i)^2$: variabilité non expliquée
- $SS_{\text{exp}} = \sum(\hat{y}_i - \bar{y})^2$: variabilité expliquée

Interprétation de R^2

Valeurs possibles de R^2 :

R^2	Interprétation
1	Le modèle explique parfaitement les données
0	Le modèle n'explique aucune variance
$0 < R^2 < 1$	Le modèle explique partiellement la variance

Plus R^2 est proche de 1, plus le modèle est performant.

Définition des résidus

Un résidu est la différence entre la valeur observée y_i et la valeur prédite \hat{y}_i :

$$e_i = y_i - \hat{y}_i$$

Rôle des résidus :

- Évaluer la qualité de l'ajustement
- Identifier les valeurs aberrantes
- Vérifier les hypothèses (linéarité, homoscédasticité, indépendance, normalité)

Exemple numérique : R^2 et résidus

Données :	x_i	1	2	3	4
	y_i	2	4	5	4

Modèle : $\hat{y}_i = 2 + 0.7x_i$

x_i	y_i	\hat{y}_i	$e_i = y_i - \hat{y}_i$
1	2	2.7	-0.7
2	4	3.4	0.6
3	5	4.1	0.9
4	4	4.8	-0.8

$$R^2 = \frac{2.45}{4.75} = 0.51$$

→ Le modèle explique environ 51% de la variance.

Exemple corrigé 1 : données simples

Soit les données :

x_i	1	2	3	4
y_i	2	4	5	4

Étapes :

- $\bar{x} = 2.5$, $\bar{y} = 3.75$
- $\hat{\beta}_1 = \frac{(13.5)}{5} = 0.7$
- $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x} = 2$
- Équation estimée : $\hat{Y} = 2 + 0.7X$

Conclusion

- La régression linéaire est un outil puissant de modélisation
- Valider les hypothèses est essentiel
- Peut être généralisée à la régression multiple

Régression Linéaire Multiple

Pr. A. Fadil

EMSI RABAT

30 octobre 2025

Plan du cours

- 1 Introduction
- 2 Définitions
- 3 Formulation du modèle
- 4 Hypothèses du modèle
- 5 Estimation par moindres carrés
- 6 Interprétation
- 7 Qualité de l'ajustement
- 8 Exemple
- 9 Conclusion

Introduction

- 1 Introduction
- 2 Définitions
- 3 Formulation du modèle
- 4 Hypothèses du modèle
- 5 Estimation par moindres carrés
- 6 Interprétation
- 7 Qualité de l'ajustement
- 8 Exemple
- 9 Conclusion

Pourquoi la régression multiple ?

- La régression linéaire multiple permet d'étudier l'effet de plusieurs variables explicatives (prédicteurs) sur une variable réponse.
- Elle est utile pour comprendre, modéliser et prédire une variable quantitative en fonction de plusieurs facteurs.
- **Exemple** : Prédire la pression artérielle en fonction de l'âge, du poids et du niveau de stress.

Définitions

- 1 Introduction
- 2 Définitions
- 3 Formulation du modèle
- 4 Hypothèses du modèle
- 5 Estimation par moindres carrés
- 6 Interprétation
- 7 Qualité de l'ajustement
- 8 Exemple
- 9 Conclusion

Variables et concepts clés

- **Variable réponse (dépendante)** : variable que l'on cherche à modéliser ou à prédire (Y).
- **Variables explicatives (indépendantes)** : variables qui influencent ou expliquent la variable réponse (X_1, X_2, \dots, X_p).
- **Coefficients de régression** (β_j) : mesure de l'effet de chaque variable explicative sur Y .
- **Erreur résiduelle** (ε) : différence entre la valeur observée et la valeur prédictive.

Formulation du modèle

- 1 Introduction
- 2 Définitions
- 3 Formulation du modèle
- 4 Hypothèses du modèle
- 5 Estimation par moindres carrés
- 6 Interprétation
- 7 Qualité de l'ajustement
- 8 Exemple
- 9 Conclusion

Modèle mathématique

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \varepsilon_i$$

En notation matricielle :

$$Y = X\beta + \varepsilon$$

- X : matrice $n \times (p + 1)$ des données (la première colonne contient des 1 pour l'intercept).
- β : vecteur des coefficients de régression.
- ε : vecteur des erreurs aléatoires.

Hypothèses du modèle

- 1 Introduction
- 2 Définitions
- 3 Formulation du modèle
- 4 Hypothèses du modèle
- 5 Estimation par moindres carrés
- 6 Interprétation
- 7 Qualité de l'ajustement
- 8 Exemple
- 9 Conclusion

Hypothèses classiques

- ① **Linéarité** : la relation entre chaque X_j et Y est linéaire.
- ② **Espérance nulle des erreurs** : $\mathbb{E}[\varepsilon_i] = 0$.
- ③ **Homoscédasticité** : la variance des erreurs est constante ($\text{Var}(\varepsilon_i) = \sigma^2$).
- ④ **Indépendance** : les erreurs sont indépendantes entre elles.
- ⑤ **Normalité** : les erreurs sont distribuées normalement (utilisé pour les tests).

Estimation par moindres carrés

- 1 Introduction
- 2 Définitions
- 3 Formulation du modèle
- 4 Hypothèses du modèle
- 5 Estimation par moindres carrés
- 6 Interprétation
- 7 Qualité de l'ajustement
- 8 Exemple
- 9 Conclusion

Moindres carrés ordinaires (MCO)

- Objectif : trouver les β_j qui minimisent la somme des carrés des résidus.

$$\min_{\beta} \|Y - X\beta\|^2$$

Solution

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Interprétation

- 1 Introduction
- 2 Définitions
- 3 Formulation du modèle
- 4 Hypothèses du modèle
- 5 Estimation par moindres carrés
- 6 Interprétation
- 7 Qualité de l'ajustement
- 8 Exemple
- 9 Conclusion

Interprétation des coefficients

- β_j : variation moyenne de Y lorsque X_j augmente d'une unité, toutes les autres variables étant maintenues constantes.
- β_0 : valeur prédictive de Y lorsque toutes les variables explicatives valent 0 (intercept).

Qualité de l'ajustement

- 1 Introduction
- 2 Définitions
- 3 Formulation du modèle
- 4 Hypothèses du modèle
- 5 Estimation par moindres carrés
- 6 Interprétation
- 7 Qualité de l'ajustement
- 8 Exemple
- 9 Conclusion

R^2 et $R^2_{\text{ajusté}}$

- **Coefficient de détermination R^2** : proportion de la variabilité de Y expliquée par le modèle.

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

- **R^2 ajusté** : corrige R^2 pour le nombre de variables.

$$R^2_{\text{ajusté}} = 1 - \left(\frac{1 - R^2}{n - p - 1} \right) (n - 1)$$

Remarque :

$$R^2_{\text{ajusté}} \leq R^2$$

Quelle est la différence entre le R au carré ajusté et le R au carré ?

Bien que le r-carré et le r-carré ajusté évaluent tous deux la performance du modèle de régression, il existe une différence essentielle entre les deux mesures. La valeur du carré r augmente toujours ou reste la même lorsque des prédicteurs sont ajoutés au modèle, même si ces prédicteurs n'améliorent pas de manière significative le pouvoir explicatif du modèle. Ce problème peut donner une impression trompeuse de l'efficacité du modèle.

Le r-carré ajusté ajuste la valeur du r-carré pour tenir compte du nombre de variables indépendantes dans le modèle. La valeur ajustée du r-carré peut diminuer si un nouveau prédicteur n'améliore pas l'adéquation du modèle, ce qui en fait une mesure plus fiable de la précision du modèle. C'est pourquoi le r-carré ajusté peut être utilisé comme un outil par les analystes de données pour les aider à décider quels prédicteurs inclure.

Exemple

- 1 Introduction
- 2 Définitions
- 3 Formulation du modèle
- 4 Hypothèses du modèle
- 5 Estimation par moindres carrés
- 6 Interprétation
- 7 Qualité de l'ajustement
- 8 Exemple
- 9 Conclusion

Exemple corrigé : Enoncé

On souhaite modéliser le score d'un étudiant (Y) en fonction de :

- X_1 : nombre d'heures d'étude par jour
- X_2 : nombre d'heures de sommeil

Données

X_1	X_2	Y
5	7	68
7	6	75
8	8	85
6	5	70
9	7	90

Questions :

- 1 Estimer le modèle de régression

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2$$

- 2 Interpréter les coefficients estimés

- 3 Calculer le score prédit pour $X_1 = 6, X_2 = 6$

Exemple corrigé : Résolution

- Estimation par moindres carrés :

$$\hat{Y} = 28.45 + 5.37X_1 + 1.74X_2$$

- Interprétation :
 - ▶ Une heure d'étude supplémentaire augmente Y de 5.37 points.
 - ▶ Une heure de sommeil supplémentaire augmente Y de 1.74 points.
- Prédiction pour $X_1 = 6$, $X_2 = 6$:

$$\hat{Y} = 28.45 + 5.37 \times 6 + 1.74 \times 6 = 71.11$$

Conclusion

- 1 Introduction
- 2 Définitions
- 3 Formulation du modèle
- 4 Hypothèses du modèle
- 5 Estimation par moindres carrés
- 6 Interprétation
- 7 Qualité de l'ajustement
- 8 Exemple
- 9 Conclusion

Résumé

- La régression multiple permet de modéliser une variable continue en fonction de plusieurs facteurs.
- La qualité du modèle se juge par R^2 .