

Exercices Machine Learning

Régression Linéaire, KNN, K-means, Arbre de Décision

AmineGR03

5 février 2026

Table des matières

1	Régression Linéaire	2
1.1	Exercice 1 : Calcul de la MSE et des paramètres	2
1.2	Exercice 2 : Gradient Descent	2
1.3	Exercice 3 : Questions de cours	3
2	K-Nearest Neighbors (KNN)	4
2.1	Exercice 1 : Calcul manuel avec petit dataset	4
2.2	Exercice 2 : Matrice de confusion et métriques	4
2.3	Exercice 3 : Questions de cours	5
3	K-Means Clustering	7
3.1	Exercice 1 : Calcul manuel de l'algorithme	7
3.2	Exercice 2 : Code Python	7
3.3	Exercice 3 : Questions de cours	8
4	Arbre de Décision	9
4.1	Exercice 1 : Calcul de l'entropie et du gain d'information	9
4.2	Exercice 2 : Calcul du Gini Impurity	10
4.3	Exercice 3 : Questions de cours	10
5	Conclusion	11

Régression Linéaire

Exercice 1 : Calcul de la MSE et des paramètres

Question

On considère le dataset suivant pour prédire le salaire (Y) en fonction des années d'expérience (X) :

Années d'expérience (X)	Salaire (Y)
1	45000
2	50000
3	60000
4	80000
5	110000

Questions :

1. Calculez manuellement les paramètres a (pente) et b (ordonnée à l'origine) de la régression linéaire $\hat{Y} = aX + b$ en utilisant les formules :

$$a = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2}$$

$$b = \frac{\sum Y - a \sum X}{n}$$

2. Calculez les prédictions $\hat{Y}$ pour chaque point.
3. Calculez la MSE (Mean Squared Error) :

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

4. Interprétez les valeurs de a et b dans le contexte du problème.

Exercice 2 : Gradient Descent

Question

On souhaite entraîner un modèle de régression linéaire avec le Gradient Descent.

Données initiales :

- $a_0 = 0$ (pente initiale)
- $b_0 = 0$ (biais initial)
- Taux d'apprentissage $\alpha = 0.01$
- Dataset : $(X_1 = 2, Y_1 = 4)$, $(X_2 = 3, Y_2 = 6)$, $(X_3 = 4, Y_3 = 8)$

Questions :

1. Calculez les dérivées partielles de la fonction de coût MSE par rapport à a et b :

$$\frac{\partial MSE}{\partial a} = \frac{2}{n} \sum_{i=1}^n X_i (\hat{Y}_i - Y_i)$$

$$\frac{\partial MSE}{\partial b} = \frac{2}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i)$$

2. Effectuez une itération du Gradient Descent :

$$a_{new} = a_{old} - \alpha \frac{\partial MSE}{\partial a}$$

$$b_{new} = b_{old} - \alpha \frac{\partial MSE}{\partial b}$$

3. Calculez la nouvelle valeur de la MSE après cette itération.
4. Expliquez pourquoi le Gradient Descent converge vers les valeurs optimales.

Exercice 3 : Questions de cours

Question

Questions théoriques :

1. Quelle est la différence entre la régression linéaire simple et la régression linéaire multiple ?
2. Expliquez ce qu'est la MSE et pourquoi on l'utilise comme fonction de coût.
3. Qu'est-ce que le Gradient Descent et comment fonctionne-t-il ?
4. Quelle est la différence entre le Gradient Descent batch, stochastique et mini-batch ?
5. Qu'est-ce que le coefficient de détermination R^2 et comment l'interpréter ?
6. Expliquez le problème du surapprentissage (overfitting) dans le contexte de la régression linéaire.

K-Nearest Neighbors (KNN)

Exercice 1 : Calcul manuel avec petit dataset

Données

On considère un dataset de classification binaire avec 2 caractéristiques (X1, X2) :

Point	X1	X2	Classe
A	1	2	Rouge
B	2	3	Rouge
C	3	1	Bleu
D	4	2	Bleu
E	5	3	Bleu

On souhaite classer le point de test $T = (3, 2)$.

Question

Questions :

1. Calculez la distance euclidienne entre le point T et tous les points du dataset :

$$d(T, P_i) = \sqrt{(X1_T - X1_i)^2 + (X2_T - X2_i)^2}$$

2. Pour $k = 1$, quelle est la classe prédite pour T ? Justifiez.
3. Pour $k = 3$, quels sont les 3 plus proches voisins ? Quelle est la classe prédite ?
4. Pour $k = 5$, quelle est la classe prédite ? Que remarquez-vous ?
5. Discutez de l'influence du choix de k sur les résultats.

Exercice 2 : Matrice de confusion et métriques

Données

On a testé un modèle KNN ($k = 3$) sur un dataset de test et obtenu les résultats suivants :

Point	Classe réelle	Classe prédite
1	Positif	Positif
2	Positif	Positif
3	Positif	Négatif
4	Négatif	Positif
5	Négatif	Négatif
6	Négatif	Négatif
7	Négatif	Négatif
8	Positif	Positif
9	Positif	Négatif
10	Négatif	Négatif

Question

Questions :

1. Construisez la matrice de confusion (2x2) avec les valeurs de TP, TN, FP, FN.
2. Expliquez la signification de chaque métrique :
 - TP (True Positive)
 - TN (True Negative)
 - FP (False Positive)
 - FN (False Negative)
3. Calculez les métriques suivantes :

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall (Sensitivity)} = \frac{TP}{TP + FN}$$

$$\text{Specificity} = \frac{TN}{TN + FP}$$

$$\text{F1-Score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

4. Interprétez chaque métrique dans le contexte d'un problème médical (détection de maladie).
5. Dans quel cas privilégieriez-vous la Precision plutôt que le Recall ?

Exercice 3 : Questions de cours

Question

Questions théoriques :

1. Expliquez le principe de l'algorithme KNN.
2. Quels sont les avantages et inconvénients de KNN ?
3. Comment choisir la valeur optimale de k ?
4. Quelle est l'influence de la normalisation des données sur KNN ?
5. Quelle distance utiliser avec KNN ? Comparez la distance euclidienne, manhattan et minkowski.
6. Pourquoi KNN est-il considéré comme un algorithme "lazy learner" ?
7. Expliquez le problème de la malédiction de la dimensionnalité avec KNN.

K-Means Clustering

Exercice 1 : Calcul manuel de l'algorithme

Données

On considère 6 points dans un espace 2D :

Point	Coordonnées (X, Y)
P1	(1, 2)
P2	(2, 3)
P3	(3, 1)
P4	(8, 7)
P5	(9, 8)
P6	(7, 9)

On souhaite effectuer un clustering avec $k = 2$ clusters.

Question

Questions :

1. Initialisez aléatoirement 2 centroïdes : $C1 = (2, 2)$ et $C2 = (8, 8)$.
2. **Étape 1 - Assignment** : Assignez chaque point au cluster le plus proche en calculant les distances euclidiennes.
3. **Étape 2 - Update** : Recalculez les centroïdes comme la moyenne des points de chaque cluster.
4. Répétez les étapes 1 et 2 jusqu'à convergence (les centroïdes ne changent plus).
5. Calculez l'inertie (within-cluster sum of squares) :

$$Inertie = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

où μ_i est le centroïde du cluster C_i .

6. Que se passe-t-il si on choisit $k = 3$ au lieu de $k = 2$?

Exercice 2 : Code Python

Question

Questions de programmation :

1. Écrivez une fonction Python qui calcule la distance euclidienne entre deux points.
2. Écrivez une fonction qui assigne chaque point au cluster le plus proche.
3. Écrivez une fonction qui met à jour les centroïdes.
4. Implémentez l'algorithme K-means complet avec un critère d'arrêt (nombre max d'itérations ou convergence).
5. Utilisez sklearn pour comparer vos résultats avec l'implémentation standard.

Exercice 3 : Questions de cours

Question

Questions théoriques :

1. Expliquez le principe de l'algorithme K-means étape par étape.
2. Quels sont les avantages et inconvénients de K-means ?
3. Comment choisir le nombre optimal de clusters k ? Mentionnez la méthode du coude (elbow method).
4. Pourquoi l'initialisation aléatoire des centroïdes peut-elle affecter les résultats ?
5. Qu'est-ce que l'inertie (within-cluster sum of squares) ?
6. Expliquez le problème des clusters vides dans K-means.
7. Quelle est la différence entre le clustering hiérarchique et K-means ?
8. Pourquoi K-means suppose-t-il que les clusters sont sphériques et de taille similaire ?

Arbre de Décision

Exercice 1 : Calcul de l'entropie et du gain d'information

Données

On considère un dataset de classification pour décider si on joue au tennis :

Jour	Outlook	Température	Humidité	Jouer
1	Ensoleillé	Chaude	Élevée	Non
2	Ensoleillé	Chaude	Élevée	Non
3	Nuageux	Chaude	Élevée	Oui
4	Pluvieux	Douce	Élevée	Oui
5	Pluvieux	Fraîche	Normale	Oui
6	Pluvieux	Fraîche	Normale	Non
7	Nuageux	Fraîche	Normale	Oui
8	Ensoleillé	Douce	Élevée	Non
9	Ensoleillé	Fraîche	Normale	Oui
10	Pluvieux	Douce	Normale	Oui
11	Ensoleillé	Douce	Normale	Oui
12	Nuageux	Douce	Élevée	Oui
13	Nuageux	Chaude	Normale	Oui
14	Pluvieux	Douce	Élevée	Non

Question

Questions :

1. Calculez l'entropie initiale du dataset :

$$Entropie(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

où p_i est la proportion de la classe i dans l'ensemble S .

2. Calculez l'entropie pour chaque attribut (Outlook, Température, Humidité) :

$$Entropie(S, A) = \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} Entropie(S_v)$$

où S_v est le sous-ensemble de S où l'attribut A a la valeur v .

3. Calculez le gain d'information pour chaque attribut :

$$Gain(S, A) = Entropie(S) - Entropie(S, A)$$

4. Quel attribut doit être choisi comme racine de l'arbre ? Justifiez.
5. Construisez l'arbre de décision complet en répétant le processus pour chaque nœud.
6. Utilisez l'arbre pour classer un nouveau jour : (Ensoleillé, Chaude, Normale).

Exercice 2 : Calcul du Gini Impurity

Question

Questions :

1. Calculez l'impureté de Gini initiale du dataset de l'exercice 1 :

$$Gini(S) = 1 - \sum_{i=1}^c p_i^2$$

2. Calculez le Gini Gain pour chaque attribut :

$$Gini(S, A) = \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Gini(S_v)$$

$$GiniGain(S, A) = Gini(S) - Gini(S, A)$$

3. Comparez les résultats obtenus avec l'entropie et le Gini. Quel critère choisiriez-vous et pourquoi ?

Exercice 3 : Questions de cours

Question

Questions théoriques :

1. Expliquez le principe de construction d'un arbre de décision.
2. Quelle est la différence entre l'entropie et l'impureté de Gini ?
3. Qu'est-ce que le gain d'information et comment l'utilise-t-on ?
4. Expliquez le problème du surapprentissage (overfitting) avec les arbres de décision.
5. Quelles sont les techniques d'élagage (pruning) pour éviter le surapprentissage ?
6. Quelle est la différence entre le pré-élagage (pre-pruning) et le post-élagage (post-pruning) ?
7. Comment gérer les valeurs manquantes dans un arbre de décision ?
8. Quels sont les avantages et inconvénients des arbres de décision ?
9. Expliquez le concept de forêt aléatoire (Random Forest) et son lien avec les arbres de décision.

Conclusion

Ces exercices couvrent les concepts fondamentaux du Machine Learning :

- **Régression Linéaire** : Calcul des paramètres, MSE, Gradient Descent
- **KNN** : Classification avec calculs manuels, matrice de confusion, métriques
- **K-means** : Clustering avec calculs itératifs et implémentation
- **Arbre de Décision** : Entropie, gain d'information, construction d'arbre

Bon courage pour vos révisions !